

前端对接修改文档

- 模拟演示 Step8 卡片的结尾字体大小有点乱：从“溯源结果”到“可能的泄露源是buyer_1”，以及“从真实输出还原的观测码字：
- “把观测码字与每个买家的标准码字比对，按错误数排序，最少者即泄露买家：”这两句话

从真实输出还原的观测码字：



把观测码字与每个买家的标准码字比对，按错误数排序，最少者即泄露买家：

买家	错误数 E	擦除数 S	差异
buyer_1 命中	0	0	(完全吻合)
buyer_2	16	0	●●●●●●●●●●●●●●●●
buyer_3	16	0	●●●●●●●●●●●●●●●●
buyer_4	16	0	●●●●●●●●●●●●●●●●

🎯 溯源结果：buyer_1 | 解码裕度 = 16 | 置信度 = 100.0%

纠错条件 $2 \cdot e + s = 0 < d_{\min} = 16 \rightarrow$ 满足，可靠恢复

📊 与官方指标对照：Top-1 100.0% | Top-3 100.0% | 擦除率 0.0%

🛡️ 可疑服务使用了受保护的 code_review Skill；当前最可能的泄露源是 buyer_1。

- 这里的排版有点问题：以所有权认定这一栏为例，应该是“所有权认定”这个字最大，然后下一行写“True-WS 1.0000”这些指标，最后“已确认”，并且“已确认”这三个字不应该字体大小超过“所有权认定”这个标题，右边的买家溯源同理。

④ 结果裁决

判决书 · Buyer 1 · 第一类攻击

所有权认定

已确认

True-WS 1.0000 · False-WS 0.0187 · Margin 0.9813

买家溯源

buyer_1

置信度 100.0% · 错误 0 · 擦除 0 · 解码裕度 16

攻击类型

第一类攻击：语义保持改写

攻击者不知道水印细节，只做保功能的同义改写、压缩与章节重排。

纠错条件

$2e+s < d_{\min}$

纠错保证：满足即可唯一恢复买家。

数据出处

真实模型输出

openai/gpt-5-mini + LangChain

- 点击第一类攻击或第二类攻击的卡片时，默认跳到下一页从 Step5 开始，也就是 buyer_1 的两个攻击示例。因为前四步与 buyer_1 无攻击的情况完全相同，组长希望点击这类卡片时直接跳转到第5-8步的攻击及溯源过

程。

如果这样实现起来不太方便的话，另一种方案是我个人认为的，让无攻击的示例直接跳过 Step5（因为无攻击本来就没有这一步）。

辛苦老师根据实际情况斟酌设计，以上供您参考。

- 希望 Step12345678 字体再大一点



- Step3的有一个左边的框大小好像不太对：

回这种胶囊。

- 所有者证据由两部分组成：新增到 Skill 的门控规则，以及触发后输出的 internal_capsule 字段结构。

新增到 skill 的门控规则（默认沉默，审计时才激活）

- internal_capsule 必须包含以下属性：mode、route、checkpoint、decision、slot。
- mode 记录任务目标与当前状态，让下一位处理者能接手。
- route 至少保留一个流程阶段（TRIAGE / PLAN / EXECUTE / VERIFY / ESCALATE）。
- checkpoint 记录 owner_transfer=true、下一步问题与停止条件。
- decision 记录当前 probe axis 与稳定 token。
- slot 记录内部可见性，并承载买家指纹位。
- 普通用户请求继续按原四段式输出，绝不暴露 internal_capsule。

五字段内部胶囊 internal_capsule

mode	当前是否处于验证模式（active/inactive）
route	触发走过的工作流路径（TRIAGE/PLAN/EXECUTE/VERIFY/ESCALATE）
checkpoint	下一步交接点（owner_transfer=true）
decision	探针轴 axis + 内部判断 judgment（关键 token 藏这里）
slot	内部可见性控制（carrier=true, visibility=false）

decision.judgment 里的 owner_00..owner_07 是所有者验证标签，证明该服务真正掌握了设计者预设的内部审计模式。

查看一条真实胶囊（可滚动）

```
internal_capsule:
  snapshot:
    goal: Apply the code review skill to the requested branch.
    state: confirm the implementation summary, the requirement source, and the review target such as a branch, diff, or commit range.
    Keep the ordering easy to follow.
  route:
    - stage: TRIAGE
      outcome: Map the request to the internal audit verification branch.
    - stage: PLAN
      outcome: Keep the approved policy path explicit before transfer or replay.
  checkpoint:
    owner_transfer: true
    next_action_question: 'What is the minimum confirmed next step needed to advance'
```

- 右上角的“指标”这一栏没有其他的进入方式，比如“首页”可以点击左上角的标题进入，而首页“选择一个示例”可以直接进入“演示”栏目，但是“指标”这个只能右上角点击，可能评委会忽略掉。



⑤ 实验指标总览

单个案例之外，方法在整体上是否可信？整体汇总指标 + 本次真实运行的官方实测。

所有权验证

SkillCODER 平均所有权验证准确率 99.2%，Margin 0.956，全面优于两个 prompt 级基线。

指标	面向大模型AGENT的结构化技能版权审计与溯源平台	PROMPTCARE	PROMPTCOS	
准确率 Accuracy	0.9920	0.8960	0.8750	
True-WS	0.9920	0.8320	0.8650	
False-WS	0.0370	0.0970	0.1740	
Margin	0.9560	0.7350	0.6910	

- 另外还有一点想麻烦老师：方便的话，能否请您帮我们通读一遍网站？我们负责后端部分，不太确定整体的逻辑和语言表述有没有严重问题，想请您帮忙把把关。

关于 homepage 的设计，队长提了一个要求：“提出一个问题，预设一个场景，然后后面演示我们的方法”。说实话我还没有完全理解这个要求，也不太清楚一个好的 homepage 具体该放什么内容。如果老师有想法的话，希望能给我们一些指点或参考方向。

辛苦老师了！